

UNIVERSITÉ DE SHERBROOKE

Faculté des sciences

IFT599/IFT799 : Science des données- TP1

Auteur	Email	CIP
Hannachi Mallek	hanm1601@usherbrooke.ca	hanm1601
Mamady Iii Diakite	diam2248@usherbrooke.ca	diam2248
Abdul Magide Djalo	maga5296@usherbrooke.ca	maga5296

Présenté à :

M. Jordan Félicien Masakuna

Octobre 2025

Table des matières

1 Jeu de données et programmation **5**
1.1 Jeu de données 5
1.2 Programmation et optimisation 5

2 Préparation des données **6**
2.1 Fusion des fichiers (Question 1) 6
2.2 Identification des variables non pertinentes (Question 2) 6
2.2.1 Analyse des valeurs manquantes 6
2.2.2 Analyse des redondances et données sensibles 7
2.2.3 Analyse de la variance et des variables constantes 7
2.2.4 Analyse de la pertinence métier 9
2.3 Conclusion intermédiaire 9

3 Préparation des données – Nettoyage (Question 3) **10**
3.1 Exclusion des variables non pertinentes 10
3.2 Vérification des doublons 10
3.3 Correction des types de données 10
3.4 Gestion des valeurs manquantes 11
3.5 Vérification finale 11
3.6 Conclusion du nettoyage 11

4 Création de variables dérivées (Question 4) **12**
4.1 Variables temporelles 12
4.2 Variables monétaires 12
4.3 Variables comportementales 13
4.4 Variables d'intervalles transactionnels 13
4.5 Variables géographiques et commerçants 13

5 Analyse des commerçants (Question 5) **14**
5.1 Résultats 14
5.2 Interprétation 14
5.3 Visualisation des périodes de pointe 15
5.3.1 Résumé 15

5.4 Analyse comparative et conclusions 16
5.4.1 Commerçants 16
5.4.2 Périodes de pointe 16
5.4.3 Weekend vs semaine 16
5.4.4 Types de commerces 16
5.4.5 Conclusion 16
5.5 Encodage des variables catégorielles (Question 6) 17
5.5.1 Identification 17
5.5.2 Stratégie retenue 17
5.5.3 Implémentation 17
5.5.4 Conclusion 17

6 Analyse d'association (Question 3.2.1) 18
6.1 Structure des données pour Apriori et FP-Growth 18
6.2 Préparation des transactions 18
6.3 Résultats intermédiaires 18
6.4 Conclusion 19

7 Extraction des règles d'association 19
7.1 Méthodologie 19
7.2 Résultats 19
7.3 Interprétation 19

8 Codes MCC et identification des dépenses élevées 20
8.1 Montants moyens par MCC 20
8.2 Segmentation des commerces 20
8.3 Patterns comportementaux 20

9 Associations entre types de cartes et commerçants 21
9.1 Test statistique 21
9.2 Profils identifiés 21

10 Analyse des transactions frauduleuses 21
10.1 Statistiques générales 21
10.2 Profils temporels et sectoriels 21
10.3 Règles de détection 22

10.4 Discussion 22

11 Interprétation des métriques d'association (Question 6) 22
11.1 Définitions des métriques 22
11.2 Résultats globaux 22
11.3 Visualisations 23
11.4 Interprétation et insights 24

12 Analyse de séquences (Question 3.3) 25
12.1 Construction des séquences 25
12.2 Extraction de motifs fréquents 25
12.3 Reconstitution des parcours clients 25
12.4 Motifs précédant les fraudes 26
12.5 Modélisation de l'évolution comportementale 26
12.6 Visualisation des séquences 26
12.7 Conclusion 27

Table des figures

1 Top 10 des variables avec le plus de valeurs manquantes dans le jeu de données fusionné. 7
2 Distribution des marques de cartes (`card_brand`). 8
3 Distribution des types de cartes (`card_type`). 8
4 Distribution des genres (`gender`). 9
5 Top 10 des commerçants selon le nombre de transactions (gauche) et selon les revenus (droite). 14
6 Transactions par heure, jour, mois et période de la journée. 15
7 Visualisation des métriques d'association : support, confiance et lift. 24
8 Analyse comparative des classes : ACP, t-SNE, UMAP et distributions (montants, heures, scores de crédit). 29
9 Projection LDA : séparation des classes et score discriminant. 30

Introduction

Dans le cadre de ce travail pratique (TP), nous exploitons un jeu de données transactionnelles bancaires afin de mettre en valeur les concepts de prétraitement, d'exploration et d'analyse statistique. L'objectif principal est d'étudier les comportements financiers des clients et de caractériser les transactions frauduleuses à l'aide d'outils d'analyse d'association, de séquences et de comparaison statistique.

Une attention particulière est portée à la qualité de la préparation des données, à la création de variables dérivées et à l'interprétation critique des résultats. Ce rapport présente la démarche suivie, depuis la préparation des données jusqu'à l'analyse des résultats.

1 Jeu de données et programmation

1.1 Jeu de données

Le jeu de données utilisé regroupe différentes sources liées aux transactions financières d'une institution bancaire. Il inclut :

— des transactions (montants, dates, commerçants, identifiants de cartes et clients),
— des informations sur les cartes (type, marque, limite de crédit, activation),
— des informations utilisateurs (profil client, données démographiques et financières),
— des codes MCC (classification des commerçants),
— et des étiquettes de fraude (indiquant si la transaction est légitime ou frauduleuse).

Ces fichiers, initialement séparés (CSV et JSON), ont été consolidés afin de permettre une analyse intégrée.

1.2 Programmation et optimisation

L'environnement de programmation choisi est **Python**, avec les bibliothèques `pandas`, `NumPy`, `matplotlib`, `seaborn` et `scikit-learn`.

Afin de traiter efficacement ce volume important (**plus de 13 millions de transactions initiales**), une stratégie d'échantillonnage intelligent a été mise en place :

— seuls les fichiers volumineux ont été réduits à un échantillon de **5%** (665 296 transactions),

— les fichiers plus petits (cartes, utilisateurs, MCC, labels de fraude) ont été conservés dans leur intégralité.

Cette approche assure la **reproductibilité des résultats** (`RANDOM_STATE = 42`) tout en réduisant le temps de traitement et l'utilisation mémoire, sans compromettre la représentativité statistique.

2 Préparation des données

2.1 Fusion des fichiers (Question 1)

La première étape de préparation a consisté à fusionner les différentes sources de données afin d'obtenir un jeu unifié. Le processus a suivi plusieurs étapes :

1. **Renommage des colonnes clés** : les colonnes identifiantes ont été renommées pour éviter les conflits (`id` → `card_id` dans `cards`, `id` → `client_id` dans `users`).
2. **Jointure transactions–cartes** : fusion sur `card_id` (LEFT JOIN), conservant l'ensemble des 665 296 transactions et ajoutant les informations des cartes.
3. **Jointure avec les utilisateurs** : intégration des informations démographiques via `client_id_trans` et `client_id`.
4. **Ajout des codes MCC** : transformation du dictionnaire en `DataFrame` et jointure sur la clé `mcc`.
5. **Intégration des labels de fraude** : ajout de la variable binaire `is_fraud` ($0 =$ légitime, $1 =$ fraude).

Résultat obtenu :

— Jeu de données final : 665 296 lignes × 40 colonnes,

— Environ 1 034 730 valeurs manquantes, principalement liées aux correspondances imparfaites entre fichiers.

Cette fusion progressive a permis de constituer une base consolidée, intégrant transactions, cartes, clients, commerçants et étiquettes de fraude.

2.2 Identification des variables non pertinentes (Question 2)

2.2.1 Analyse des valeurs manquantes

— `errors` : 98,4% de valeurs manquantes → **exclue**.

— `is_fraud` : 33% de valeurs manquantes mais variable cible → **conservée**.
— `zip` et `merchant_state` : ∼ 12% de valeurs manquantes → **conservées** avec traitement d'imputation envisagé.

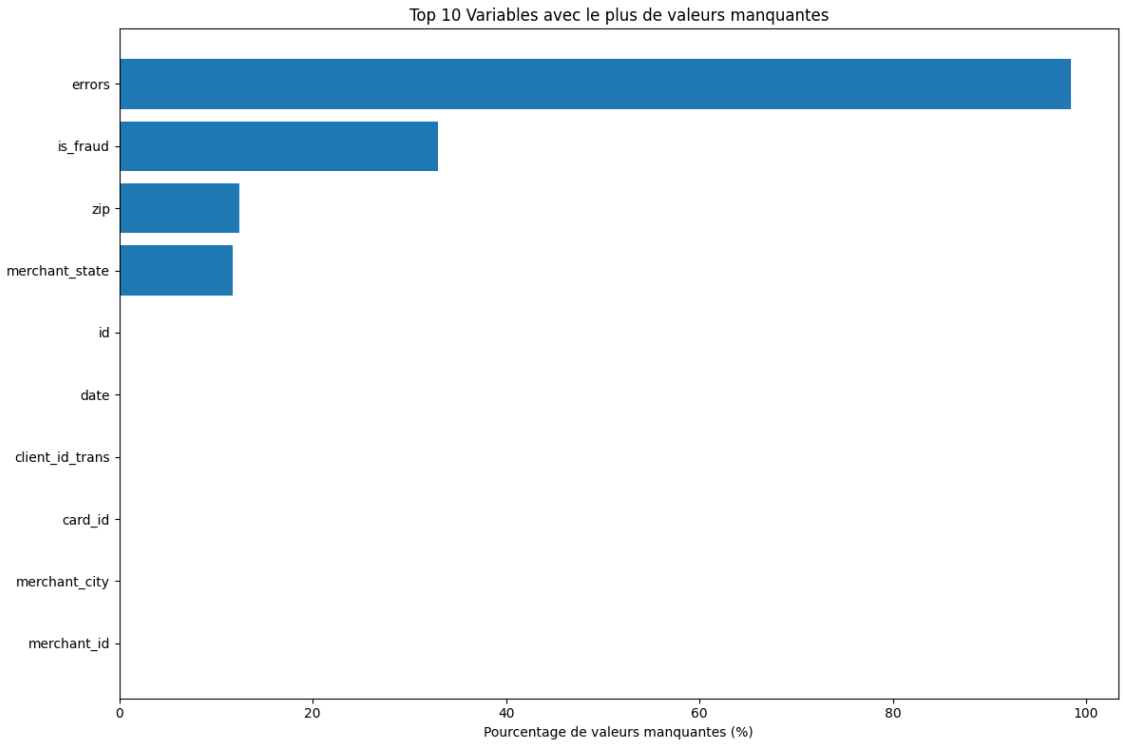


FIGURE 1 – Top 10 des variables avec le plus de valeurs manquantes dans le jeu de données fusionné.

Comme l'illustre la Figure 1, la variable `errors` présente près de 100% de valeurs manquantes, justifiant son exclusion.

2.2.2 Analyse des redondances et données sensibles

— Corrélation parfaite entre `client_id_trans`, `client_id_card` et `client_id` → conservation d'une seule colonne.
— `card_number`, `expires`, `cvv` → données sensibles et redondantes avec `card_id` → **exclues**.

2.2.3 Analyse de la variance et des variables constantes

Afin de compléter l'identification des variables non pertinentes, nous avons examiné la variance des variables numériques ainsi que la distribution des variables catégorielles.

La Figure 2 montre que la majorité des transactions sont effectuées avec des cartes Mastercard et Visa, confirmant que `card_brand` conserve une variabilité intéressante pour l'analyse. De même, la Figure 3 indique une prédominance des cartes de débit, tandis que la Figure 4 illustre une répartition relativement équilibrée entre hommes et femmes.

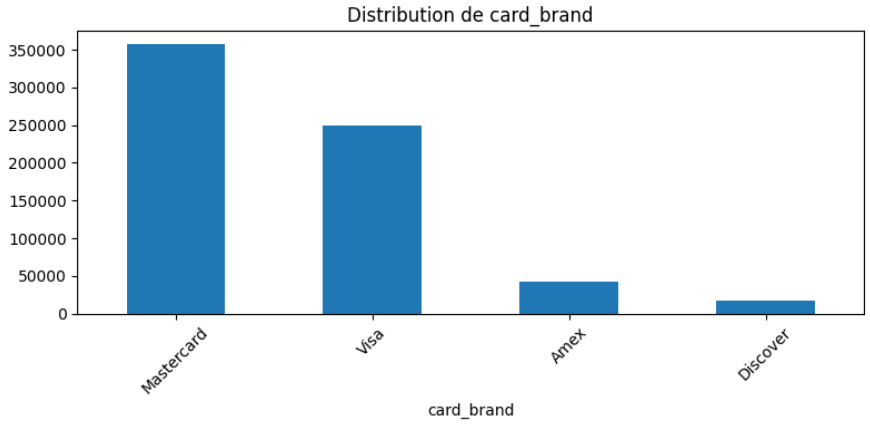


FIGURE 2 – Distribution des marques de cartes (`card_brand`).

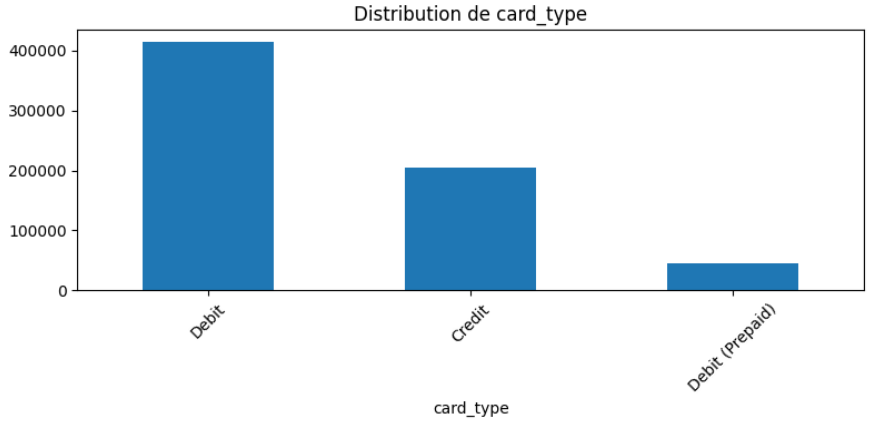


FIGURE 3 – Distribution des types de cartes (`card_type`).

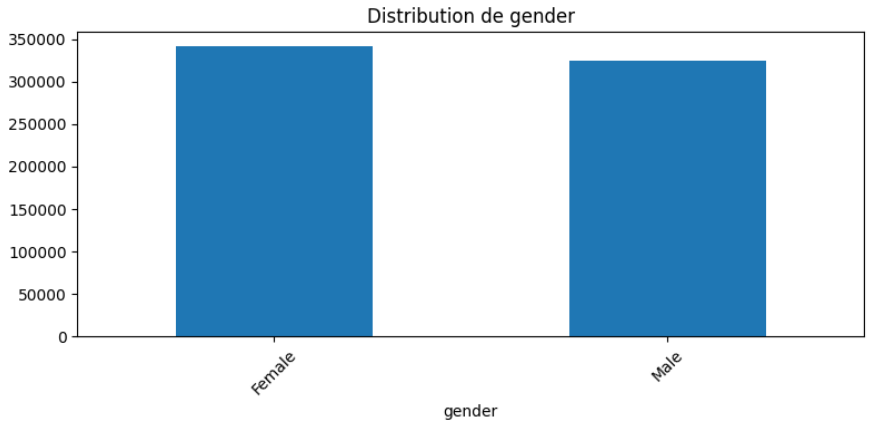


FIGURE 4 – Distribution des genres (`gender`).

2.2.4 Analyse de la pertinence métier

Pertinentes pour l'analyse d'association, de séquences et de fraude :

— `amount`, `card_type`, `card_brand`, `mcc`, `mcc_description`, `merchant_city`, `merchant_state`, `use_chip`, `gender`, `credit_score`, `date`, `merchant_id`, `is_fraud`.

Non pertinentes ou hors périmètre analytique :

— `address`, `latitude`, `longitude`, `zip`, `birth_month`, `birth_year`,

— `num_credit_cards`, `yearly_income`, `per_capita_income`, `total_debt`, `credit_limit`, `retirement_age`, etc.

2.3 Conclusion intermédiaire

Au terme de cette étape, nous avons identifié 9 variables principales à exclure :

— `errors`,

— `client_id_trans`, `client_id_card`,

— `card_number`, `cvv`, `expires`,

— `num_cards_issued`, `year_pin_last_changed`, `card_on_dark_web`.

Ces exclusions représentent environ **22,5% du dataset**, tandis que **31 variables essentielles** ont été conservées. Cette sélection permet de concentrer l'analyse sur des attributs pertinents et d'éliminer le bruit et la redondance.

3 Préparation des données – Nettoyage (Question 3)

Afin de garantir la fiabilité des analyses ultérieures, un processus rigoureux de nettoyage a été appliqué au jeu de données. Cette étape vise à éliminer les variables non pertinentes, corriger les incohérences, uniformiser les types de données et traiter les valeurs manquantes.

3.1 Exclusion des variables non pertinentes

Méthodologie. Sur la base de l'analyse de la Question 2, neuf variables ont été supprimées : `errors`, `client_id_trans`, `client_id_card`, `card_number`, `expires`, `cvv`, `num_cards_issued`, `year_pin_last_changed`, `card_on_dark_web`.

Résultats. Le dataset est passé de **40 variables à 31**, tout en conservant les 665 296 transactions.

Justification. Ces exclusions sont motivées par :

— un taux de valeurs manquantes trop élevé (`errors`, 98,4%),

— une redondance parfaite avec d'autres variables (`client_id_trans`, `client_id_card`),

— des données sensibles inutiles à l'analyse (`card_number`, `expires`, `cvv`),

— une variabilité insuffisante ou inexistante (`num_cards_issued`, `year_pin_last_changed`, `card_on_dark_web`).

3.2 Vérification des doublons

Méthodologie. Nous avons vérifié la présence de doublons complets, de transactions portant le même identifiant, ainsi que de doublons sur une combinaison de clés (`client_id`, `card_id`, `date`, `amount`).

Résultats. Aucun doublon complet ni transaction répétée n'a été détecté. Une seule combinaison clé dupliquée a été trouvée, représentant un cas isolé.

Justification. L'absence de doublons confirme la robustesse du jeu de données initial, réduisant le risque d'inflation artificielle des fréquences lors des analyses d'association ou de séquences.

3.3 Correction des types de données

Méthodologie. Des conversions ont été appliquées pour uniformiser les formats :

— la variable `amount` a été convertie en `float` (suppression du symbole $),

— les colonnes temporelles (`date`, `acct_open_date`) ont été transformées en `datetime`,
— les variables financières (`yearly_income`, `total_debt`) ont été converties en valeurs numériques.

Résultats. Au total, 6 colonnes ont été corrigées. Le dataset final contient désormais 11 colonnes entières, 7 flottantes, 11 catégorielles et 2 temporelles.

Justification. Ces corrections assurent la compatibilité avec les algorithmes statistiques et permettent de tirer parti d'analyses quantitatives fiables.

3.4 Gestion des valeurs manquantes

Méthodologie. Une stratégie différenciée a été appliquée selon la nature des variables :
— imputation par le mode pour les variables géographiques (`merchant_state = CA`, `zip = 98516`),
— conservation des valeurs manquantes pour la variable cible `is_fraud`.

Résultats. Après traitement, les valeurs manquantes ont été supprimées pour `zip` et `merchant_state`. Seules 219 329 valeurs manquantes persistent dans `is_fraud` (32,9% des cas).

Justification. Le choix de conserver les valeurs manquantes de `is_fraud` est volontaire : celles-ci représentent des transactions non étiquetées, et constituent une information à part entière à ne pas altérer.

3.5 Vérification finale

Méthodologie et résultats. Un bilan a été effectué après nettoyage :
— variables : **31**,
— transactions : **665 296**,
— valeurs manquantes : uniquement sur `is_fraud`,
— types de données : cohérents et adaptés aux analyses.

Justification. Cette vérification confirme la qualité finale du jeu de données, désormais consolidé, cohérent et prêt pour les phases d'analyse d'association et de séquences.

3.6 Conclusion du nettoyage

Le processus de nettoyage a permis de réduire le bruit, d'éliminer les redondances et de corriger les incohérences, tout en conservant les informations essentielles. Le dataset final de **665 296 transactions** $\times$ **31 variables** constitue une base robuste et exploitable

pour l'extraction de règles d'association, l'analyse séquentielle et l'étude comparative des transactions frauduleuses.

4 Création de variables dérivées (Question 4)

Afin d'enrichir le jeu de données, nous avons créé un ensemble de variables dérivées. Au total, 21 nouvelles variables ont été générées, regroupées en cinq catégories principales : temporelles, monétaires, comportementales, intervalles transactionnels et géographiques/commerçants.

4.1 Variables temporelles

Méthodologie. À partir de la variable `date`, nous avons extrait plusieurs dimensions temporelles : l'heure, le jour de la semaine, le jour du mois, le mois, l'année, ainsi qu'une catégorisation en périodes de la journée (matin, après-midi, soirée, nuit). Un indicateur binaire `is_weekend` a également été créé pour distinguer les transactions effectuées le weekend.

Résultats. 7 variables temporelles ont été générées (`hour`, `day_of_week`, `time_period`, etc.).

Justification. Ces variables permettent d'analyser les comportements transactionnels selon les moments de la journée et de détecter des anomalies temporelles (ex. transactions inhabituelles la nuit ou en weekend).

4.2 Variables monétaires

Méthodologie. Nous avons créé des indicateurs financiers incluant :

— la normalisation des montants (`amount_normalized`, Z-score),

— la catégorisation en quartiles (`amount_category`),

— le montant absolu (`amount_absolute`),

— le ratio dette/revenus (`debt_to_income_ratio`),

— et l'utilisation du crédit (`credit_utilization`).

Résultats. 5 variables monétaires dérivées ont été créées.

Justification. Ces indicateurs facilitent l'analyse quantitative et permettent de détecter des anomalies financières ou des comportements atypiques (dépenses excessives, utilisation inhabituelle du crédit).

4.3 Variables comportementales

Méthodologie. Nous avons enrichi les données clients et transactions en ajoutant :

— une catégorisation par âge (`age_category`),

— une catégorisation par score de crédit (`credit_score_category`),

— une classification par type de transaction (`transaction_type`),

— un indicateur de transaction de haute valeur (`is_high_value`, top 5%).

Résultats. 4 nouvelles variables comportementales ont été créées.

Justification. Ces variables permettent la segmentation des clients et l'identification de profils à risque, ce qui est essentiel pour l'analyse de la fraude.

4.4 Variables d'intervalles transactionnels

Méthodologie. Pour chaque client, nous avons calculé :

— le temps écoulé depuis la dernière transaction (`time_since_last_transaction`),

— le temps jusqu'à la transaction suivante (`time_until_next_transaction`),

— une catégorisation en intervalles (`interval_category`).

Résultats. 3 variables d'intervalles ont été générées.

Justification. Elles sont essentielles pour l'analyse séquentielle et permettent de détecter des comportements inhabituels, tels qu'une succession rapide de transactions pouvant indiquer une fraude.

4.5 Variables géographiques et commerçants

Méthodologie. À partir des variables `merchant_state` et `mcc_description`, nous avons créé :

— une classification régionale (`region` : West, South, Midwest, Northeast, Other),

— une catégorisation des commerçants (`merchant_type` : Food, Gas, Retail, Travel, Healthcare, Other).

Résultats. 2 variables supplémentaires ont été créées.

Justification. Elles permettent une analyse spatiale et sectorielle des transactions, utile pour comprendre la répartition régionale des comportements et localiser des fraudes potentielles.

5 Analyse des commerçants (Question 5)

Afin d'identifier les acteurs économiques les plus influents dans le jeu de données, nous avons étudié le **Top 10 des commerçants** selon deux indicateurs : (i) le nombre de transactions, et (ii) le revenu total généré. Les résultats sont présentés sous forme de diagrammes en secteurs (Figure 5).

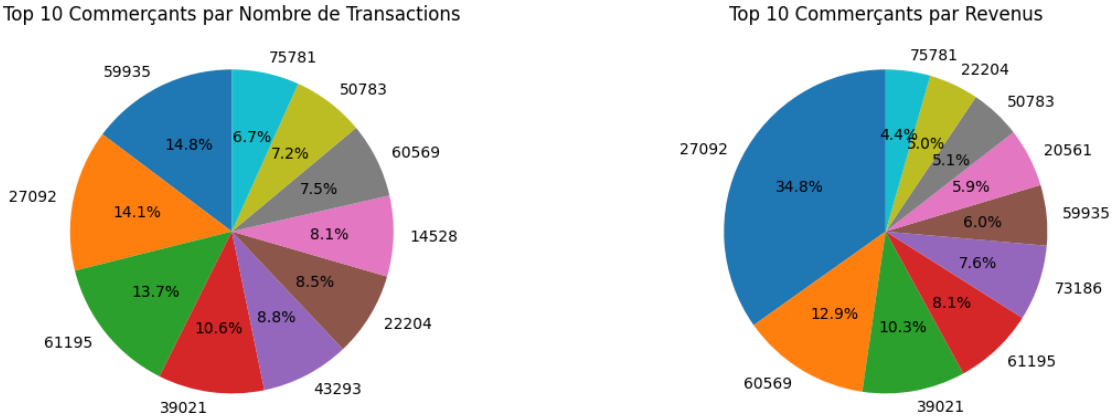


FIGURE 5 – Top 10 des commerçants selon le nombre de transactions (gauche) et selon les revenus (droite).

5.1 Résultats

— **Nombre de transactions.** Les commerçants `59935`, `27092` et `61195` se distinguent, représentant à eux seuls près de 42% des transactions totales. Le commerçant `59935` domine légèrement en volume (30 372 transactions).

— **Revenus générés.** La distribution des revenus est beaucoup plus concentrée : le commerçant `27092` génère à lui seul **34,8% des revenus** (2,63 M$), loin devant le deuxième (`60569`, 12,9%). Certains commerçants tels que `20561` apparaissent dans le Top 10 en revenus mais pas en nombre de transactions, ce qui indique des montants moyens de transaction plus élevés.

5.2 Interprétation

Cette analyse met en évidence deux dynamiques distinctes :

— Certains commerçants concentrent un **grand nombre de petites transactions**, reflétant une activité fréquente mais de faible valeur unitaire.

— D'autres génèrent un **revenu important avec moins de transactions**, suggérant des achats ponctuels mais de forte valeur (ex. commerces de luxe ou services spécialisés).

Ces distinctions sont particulièrement utiles pour l'analyse de fraude : un commerçant ayant un volume faible mais des revenus très élevés peut être plus exposé à des tentatives de fraude ciblées.

5.3 Visualisation des périodes de pointe

La Figure 6 illustre la distribution des transactions selon différentes dimensions temporelles (heure, jour, mois, période de la journée).

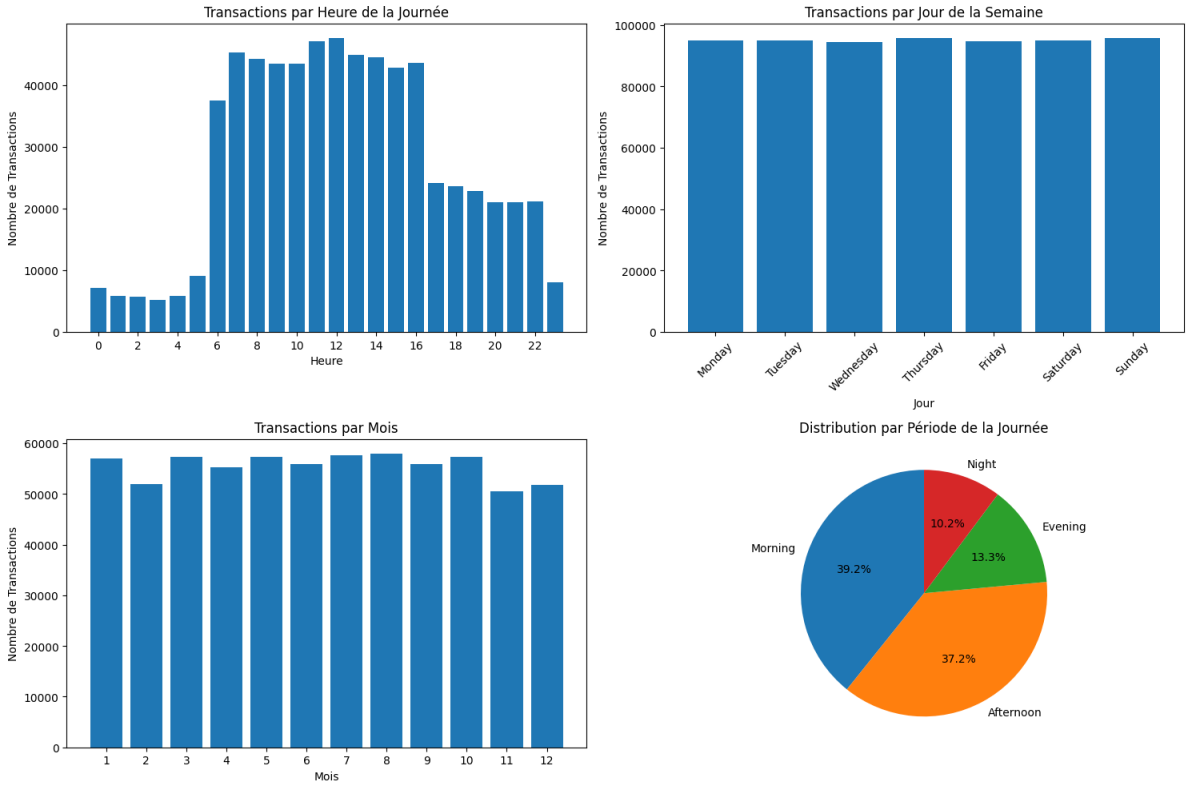


FIGURE 6 – Transactions par heure, jour, mois et période de la journée.

5.3.1 Résumé

Les transactions se concentrent principalement entre **7h et 16h**, avec un pic autour de **12h**. La répartition est stable entre semaine et weekend. L'activité reste homogène toute l'année, avec un léger pic en été. Enfin, la **matinée (39%)** et l'**après-midi (37%)** totalisent plus des trois quarts des transactions, confirmant l'importance des heures de bureau.

5.4 Analyse comparative et conclusions

Cette synthèse met en évidence les différences entre commerçants, périodes de pointe et types de commerces.

5.4.1 Commerçants

Deux profils ressortent :

— un modèle basé sur un **volume important de petites transactions** (ex. commerçant 59935, plus de 30 000 opérations à faible montant),

— un modèle reposant sur des **transactions moins fréquentes mais de forte valeur** (ex. 27092 et 73186, montants moyens supérieurs à 90$).

Cela illustre deux stratégies économiques complémentaires : la rentabilité par la masse ou par la valeur unitaire.

5.4.2 Périodes de pointe

Les transactions culminent à **12h**, le **jeudi** et durant le mois d'**août**. Ces tendances reflètent des habitudes de consommation récurrentes : repas du midi, fin de semaine active et dépenses saisonnières liées à l'été.

5.4.3 Weekend vs semaine

Près de **29%** des transactions ont lieu le weekend. Cette proportion montre que si l'essentiel de l'activité se concentre en semaine, une part non négligeable subsiste les samedis et dimanches, ce qui confirme l'importance d'intégrer le weekend dans les analyses de risque.

5.4.4 Types de commerces

La segmentation MCC indique la domination de la catégorie **Other** (42%), suivie de l'**alimentation** (34%) et du **retail** (17%). L'alimentaire s'impose comme un secteur clé des dépenses courantes, tandis que la catégorie générique **Other** reflète une diversité d'activités nécessitant un affinage.

5.4.5 Conclusion

L'analyse comparative souligne :

— des profils contrastés de commerçants (volume vs valeur unitaire),
— des périodes critiques cohérentes avec les comportements de consommation (pause déjeuner, jeudi, été),
— une part significative d'activité le weekend,
— une domination sectorielle de l'alimentaire et des services divers.

Ces résultats offrent des **indications stratégiques** pour cibler les commerçants à fort enjeu et renforcer les systèmes de détection de fraude durant les périodes sensibles.

5.5 Encodage des variables catégorielles (Question 6)

5.5.1 Identification

L'analyse du jeu de données nettoyé a révélé **19 variables catégorielles**, allant de modalités binaires (`gender`, `use_chip`) à des ensembles riches (`merchant_city` : 8 000+ modalités, `mcc_description` : 108 modalités).

5.5.2 Stratégie retenue

Une approche **hybride** a été adoptée :
— **Label Encoding** pour 5 variables à faible cardinalité ou ordonnées (`card_type`, `card_brand`, `use_chip`, `has_chip`, `gender`).
— **Conservation textuelle** pour 14 variables nominales à forte cardinalité (`merchant_city`, `mcc_description`, `region`), essentielles pour les analyses d'association et de séquences.
— Le **One-Hot Encoding** a été écarté pour éviter une explosion dimensionnelle peu utile en interprétation.

5.5.3 Implémentation

L'utilisation de `LabelEncoder` a produit 5 nouvelles variables numériques (`card_type_encoded`, etc.). Le dataset final contient **57 variables** : 38 numériques, 14 catégorielles conservées et 5 encodées.

5.5.4 Conclusion

Cette stratégie garantit :
— la **compatibilité** avec les algorithmes d'association et séquences,
— des **variables numériques compactes** pour la modélisation,

— une **interprétabilité directe** grâce au mapping réversible.

Ainsi, l'encodage retenu constitue un compromis équilibré entre expressivité, efficacité et pertinence analytique.

6 Analyse d'association (Question 3.2.1)

6.1 Structure des données pour Apriori et FP-Growth

Les algorithmes d'association tels que **Apriori** et **FP-Growth** nécessitent une structure transactionnelle adaptée, où chaque transaction est représentée comme un ensemble d'items catégoriels. Dans notre cas, une transaction bancaire ne peut pas être utilisée directement (montants numériques, identifiants uniques, etc.) : il est donc nécessaire de transformer les variables en « items » compréhensibles par ces algorithmes.

6.2 Préparation des transactions

Nous avons retenu un sous-ensemble de variables pertinentes pour l'analyse d'association : `card_type`, `card_brand`, `merchant_state`, `mcc_description`, `amount_category`, `credit_score_category`, `time_period`, `merchant_type`.

La préparation a suivi les étapes suivantes :

1. **Catégorisation des montants.** Les montants ont été transformés en quartiles (`amount_low`, `amount_medium`, `amount_high`, `amount_very_high`) afin de les convertir en variables discrètes exploitables.
2. **Catégorisation du score de crédit.** Le score a été regroupé en trois classes (`credit_low`, `credit_medium`, `credit_high`).
3. **Transformation en items textuels.** Chaque variable catégorielle a été encodée sous forme d'items lisibles (ex. `card_debit`, `brand_visa`, `mcc_grocery_stores`, `time_afternoon`, `merchant_food`).
4. **Format long transactionnel.** Les données ont été réorganisées en format *long*, où chaque ligne correspond à l'association (`client_id`, `card_id`, `itemname`). Cela donne un jeu de données de 5 322 368 lignes et 291 items uniques.

6.3 Résultats intermédiaires

La transformation a produit :

— **291 items distincts**, couvrant les dimensions carte, commerçant, montant, crédit et temps,
— un format compatible avec les algorithmes d'association,
— une distribution dominée par des items fréquents comme `card_debit` (413 870 transactions), `credit_high` (413 826 transactions), `brand_mastercard` (356 954 transactions) et `merchant_food` (227 534 transactions).

6.4 Conclusion

Cette étape de préparation est essentielle : elle transforme des transactions numériques et hétérogènes en ensembles d'items catégoriels. Le dataset ainsi obtenu est désormais prêt pour l'application des algorithmes d'association (Apriori et FP-Growth), qui permettront d'extraire des règles fréquentes du type « `brand_visa` + `amount_high` ⇒ `merchant_food` ».

7 Extraction des règles d'association

7.1 Méthodologie

Pour identifier les relations entre variables catégorielles, l'algorithme `Apriori` a été appliqué sur un échantillon représentatif (**1%** du jeu, soit 53 224 transactions et 1 219 clients). Les transactions ont été encodées sous forme binaire, avec un seuil de support fixé à 30% et une confiance minimale de 50%.

7.2 Résultats

L'analyse a produit **605 itemsets fréquents** et **3 894 règles**, révélant plusieurs associations significatives. Exemples :

— {merchant_food, card_debit} ⇒ {amount_low, brand_mastercard} (Lift = 1,209)
— {amount_very_high, brand_mastercard, time_morning} ⇒ {card_debit, merchant_food} (Lift = 1,190)

7.3 Interprétation

Ces règles mettent en évidence des comportements typiques : l'utilisation fréquente des cartes de débit Mastercard pour l'alimentation (petits montants) et leur présence aussi

sur des transactions très élevées le matin. Elles confirment l'intérêt de l'analyse d'association pour dégager des **profils de consommation récurrents**.

8 Codes MCC et identification des dépenses élevées

8.1 Montants moyens par MCC

L'analyse des montants par code MCC met en évidence les catégories de commerces associées aux **plus fortes dépenses** :

— Croisières : 1 590 $enmoyenne(mdiane 1\,225)$,
— Industrie métallurgique : 762–890 ,
— Services hospitaliers : 737 ,
— Compagnies aériennes : 736 .

À l'opposé, les commerces de nécessité affichent des montants faibles : pharmacies (45), $alimentation(22)$, salons de beauté (47).

8.2 Segmentation des commerces

— **Très élevé** (> 500\$) : croisières, métallurgie, hôtellerie haut de gamme.
— **Élevé** (200–500\$) : transport, services professionnels.
— **Moyen** (100–200\$) : commerce de détail spécialisé.
— **Faible** (< 100\$) : alimentation, retail quotidien.

8.3 Patterns comportementaux

— Les **secteurs B2B et luxe** (industrie métallurgique, voyage) concentrent des transactions rares mais très élevées.
— L'**alimentation** et le **retail** présentent des volumes massifs (227 000+ transactions) mais des montants faibles, confirmant leur rôle de consommation courante.
—

9 Associations entre types de cartes et commerçants

9.1 Test statistique

Le test du χ^2 appliqué au tableau `card_type` × `merchant_type` ($\chi^2 = 3078$, $p < 0.001$) montre une **association significative**, confirmant que l'usage des cartes dépend du type de commerce.

9.2 Profils identifiés

— **Crédit** : profil « pouvoir d'achat élevé », orienté vers les secteurs spécialisés (*Healthcare*, *Travel*, *Gas*) avec un montant moyen supérieur (54,85$).
— **Débit** : profil « consommation quotidienne », dominé par l'alimentaire (*Food*), montant moyen intermédiaire (39,32$).
— **Prépayées** : profil « contrôle budgétaire », centrées sur *Food* et *Retail*, quasi absentes du voyage, avec le montant moyen le plus faible (21,49$).

Cette segmentation met en évidence des **usages différenciés** : dépenses planifiées (crédit), achats quotidiens (débit) et gestion stricte du budget (prépayées).

10 Analyse des transactions frauduleuses

10.1 Statistiques générales

— Transactions frauduleuses : 672 (0,15% du total).
— Montant moyen : 104,5$ (vs 42,6$ pour les légitimes).
— Variabilité : écart-type 193$ (vs 80$).

10.2 Profils temporels et sectoriels

— Les fraudes se concentrent en **après-midi** (46,3% vs 37,2% légitimes).
— Sous-représentation la nuit (3,6% vs 10,2%).
— Sur-risque dans le secteur **Retail** (ratio 2,31) et **Travel** (ratio 2,11).

10.3 Règles de détection

— {Montant élevé + Commerce à risque (Retail/Travel/Gas)} $\Rightarrow$ Risque accru $\rightarrow$ capture 15,8% des fraudes avec seulement 4,1% de faux positifs.
— {Montant élevé + Heure tardive} $\Rightarrow$ Risque faible $\rightarrow$ précision 0,3%, rappel 1,5%.
— Règles géographiques : certains états (Italie, Haïti) présentent un ratio de fraude disproportionné.

10.4 Discussion

Les règles simples montrent une faible performance (F1 = 0,005), mais les **règles composites** (montant + secteur + localisation) offrent une meilleure discrimination. Cela suggère d'intégrer plusieurs dimensions dans un modèle prédictif de fraude.

11 Interprétation des métriques d'association (Question 6)

11.1 Définitions des métriques

Les règles d'association sont évaluées à l'aide de trois métriques fondamentales :
— **Support** $= P(A \cap B)$: proportion des transactions contenant simultanément l'antécédent et le conséquent. Un support élevé indique un pattern fréquent et représentatif. Seuil fixé à 30%.
— **Confiance** $= P(B|A)$: probabilité qu'une transaction contenant A contienne aussi B. Une confiance élevée traduit une forte fiabilité prédictive. Seuil fixé à 50%.
— **Lift** $= \frac{Confiance(A \Rightarrow B)}{P(B)}$: rapport entre la confiance observée et la confiance attendue si A et B étaient indépendants.
  — $Lift > 1$: association positive (renforce la probabilité),
  — $Lift = 1$: indépendance statistique,
  — $Lift < 1$: association négative.

11.2 Résultats globaux

L'extraction a produit **3 894 règles**, dont la distribution est résumée dans le Tableau 1.
— Support moyen : 35,8%, confirmant des patterns fréquents.
— Confiance moyenne : 67,8%, révélant une bonne fiabilité prédictive.
— Lift moyen : 1,072, indiquant des associations positives mais modérées.

	Support	Confiance	Lift
Moyenne	0.358	0.678	1.072
Écart-type	0.057	0.112	0.039
Min	0.300	0.500	0.898
Max	0.682	0.918	1.209

TABLE 1 – Statistiques descriptives des métriques des règles extraites.

La catégorisation qualitative montre que :

— 700 règles présentent un support élevé ($\geq 40\%$),

— 1 523 règles ont une confiance élevée ($\geq 70\%$),

— seules 4 règles affichent un lift fort (≥ 1.2).

11.3 Visualisations

Les visualisations de la Figure 7 facilitent l'interprétation :

— La relation **Support vs Confiance** met en évidence une forte densité de règles dans la zone acceptable ($Support > 30\%, Confiance > 50\%$).

— L'histogramme du **Lift** est centré autour de 1.07, confirmant la dominance d'associations modérées.

— Le **Top 10 des règles par Lift** identifie les patterns les plus significatifs, souvent liés aux transactions alimentaires par carte de débit.

— La **matrice de décision** synthétise les zones de qualité, montrant que 82% des règles respectent les seuils de sélection.

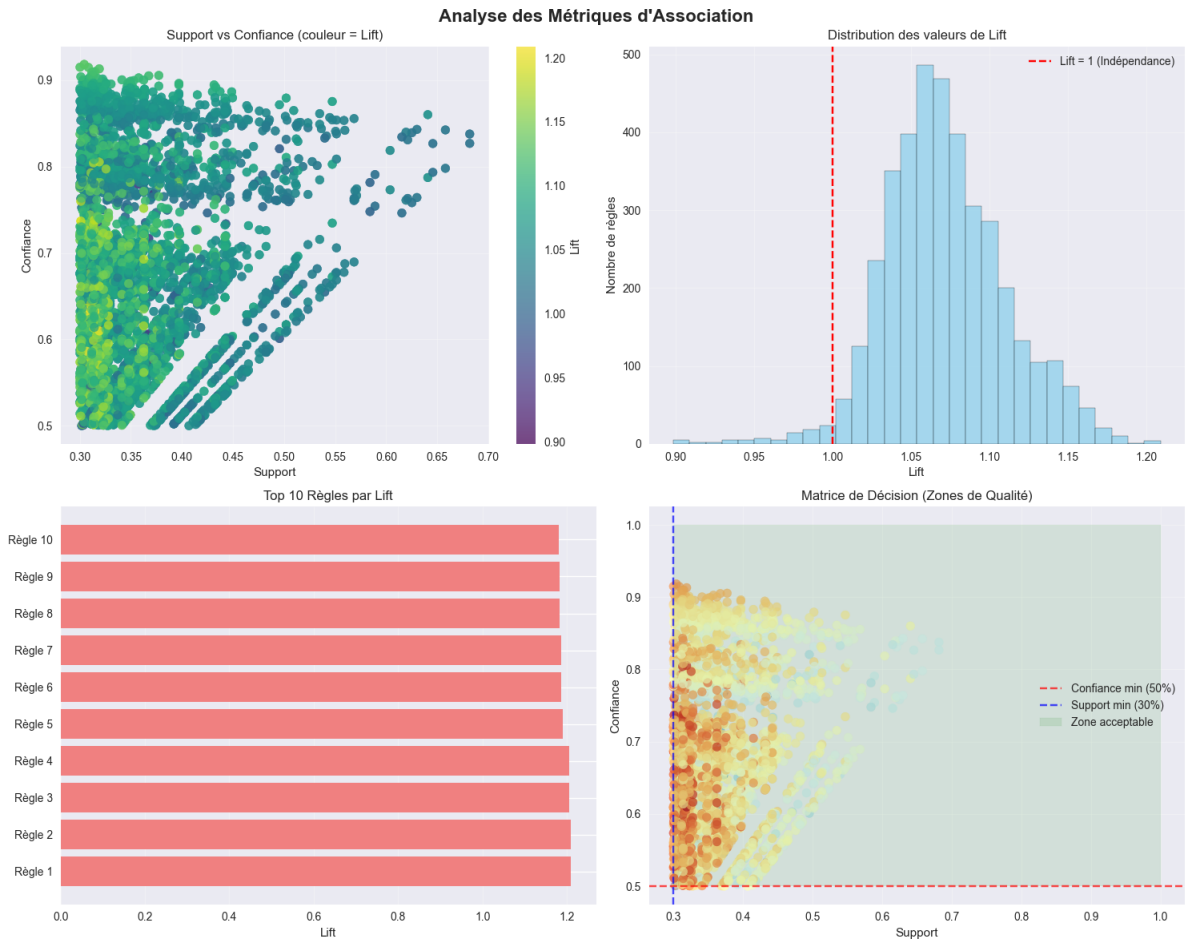


FIGURE 7 – Visualisation des métriques d'association : support, confiance et lift.

11.4 Interprétation et insights

Les meilleures règles identifiées combinent des transactions alimentaires (`merchant_food`), effectuées avec des cartes de débit Mastercard, associées à de faibles montants (`amount_low`). Par exemple, la règle :

$$\{\texttt{merchant_food}, \texttt{card_debit}\} \Rightarrow \{\texttt{brand_mastercard}, \texttt{amount_low}\}$$

présente un support de 30,7%, une confiance de 58,6% et un lift de 1,19.

Conclusion. L'ensemble des règles extraites met en évidence des comportements cohérents (achats alimentaires récurrents, usage fréquent des cartes de débit), mais peu d'associations exceptionnelles (lift > 1.2). Ces résultats suggèrent un dataset représentatif d'habitudes de consommation quotidiennes, avec un potentiel d'exploitation pour la détection de fraudes répétitives ou contextuelles.

12 Analyse de séquences (Question 3.3)

12.1 Construction des séquences

Afin de modéliser les comportements transactionnels des clients, nous avons construit des séquences chronologiques à partir du jeu de données enrichi. Chaque séquence regroupe les transactions successives d'un même client, ordonnées par `date` et complétées par des informations contextuelles (`merchant_type`, `amount_category`, `card_type`, `time_period`, etc.).

Résultats. L'échantillon étudié (100 clients) révèle :

— une longueur moyenne de séquence de **534 transactions**,

— un maximum de **2 085 transactions** pour un seul client,

— un minimum de **144 transactions**.

Cette profondeur séquentielle permet d'identifier des routines comportementales significatives.

12.2 Extraction de motifs fréquents

Nous avons appliqué une approche inspirée de **PrefixSpan** pour extraire des motifs séquentiels fréquents avec un support minimal fixé à **20%**.

Résultats.

— 61 items fréquents identifiés (ex. `Food_amount_low_Morning`),

— 3 680 paires fréquentes (ex. `Food → Food`, `Other → Other`, `Gas → Food`).

Interprétation.

— Les séquences intra-catégorie (`Food→Food`, `Other→Other`) traduisent une fidélité ou une répétition d'achats dans le même type de commerce.

— Les transitions inter-catégories (`Gas→Food`, `Other→Food`) révèlent des routines quotidiennes (déplacement puis restauration, services suivis d'achats alimentaires).

12.3 Reconstitution des parcours clients

Les parcours typiques les plus fréquents incluent :

— **Services divers** (`Other`) répétés matin et après-midi avec des montants variables → routine professionnelle.

— **Cycle alimentaire-services** (`FoodOther`) → intégration des achats alimentaires dans les routines quotidiennes.

— **Cycle essence-alimentation** (`Gas→Food→Gas`) → comportement de déplacement récurrent.

12.4 Motifs précédant les fraudes

L'analyse séquentielle révèle des motifs caractéristiques avant les transactions frauduleuses :

— **Motifs temporels** : petites transactions test en journée → transaction de très haut montant (`amount_very_high`) en soirée ou nuit (0h–5h), parfois après un intervalle très court (<1h).

— **Motifs comportementaux** : changement soudain de localisation (`merchant_state`) ou recours à des types de commerçants atypiques (ex. passage brutal de `Food` à `Travel/Healthcare`).

Ces motifs constituent des signaux d'alerte exploitables dans une logique de détection préventive.

12.5 Modélisation de l'évolution comportementale

Nous proposons une modélisation en **phases évolutives**, assimilable à un automate à états finis :

1. **Phase d'initiation** : petites dépenses sporadiques.
2. **Phase de maturation** : augmentation progressive des montants et stabilisation des habitudes.
3. **Phase de maturité** : routine stable avec montants élevés et régularité temporelle.
4. **Phase de dégradation** : inactivité croissante ou comportements anormaux (fraude, rupture de routine).

Les transitions rapides entre phases (ex. passage direct de faibles montants à des transactions très élevées en peu de temps) constituent des anomalies détectables.

12.6 Visualisation des séquences

Plusieurs méthodes de visualisation peuvent être mobilisées :

— **Diagrammes de flux (Sankey)** : mettre en évidence les parcours dominants (ex. `Other→Food→Other`).

— **Arbres séquentiels** : représenter les étapes successives des parcours clients.

— **Matrice de transition (heatmap)** : quantifier les passages d'un type de commerce à un autre.
— **Réseaux de séquences** : représenter les commerces comme des nœuds et les transitions comme des arêtes pondérées.

Ces visualisations facilitent l'identification des routines récurrentes, la segmentation comportementale et la détection d'anomalies séquentielles liées à la fraude.

12.7 Conclusion

L'analyse séquentielle permet de reconstituer les parcours clients typiques et d'identifier des motifs récurrents. Les routines observées (achats alimentaires, cycles services–alimentation, déplacements avec carburant) confirment des comportements de consommation stables. À l'inverse, les ruptures de routine (escalade rapide des montants, localisation inhabituelle, horaires nocturnes) se distinguent comme signaux précoces de transactions frauduleuses.

3.4 Recommandation sur les associations ou les séquences (10%)

Objectif

L'objectif est de concevoir un système de recommandation transactionnel exploitant les règles d'association fréquentes extraites (Apriori, FP-Growth). Ce système vise à proposer des items complémentaires (commerces, montants, périodes) en fonction de l'historique d'un client.

Approche méthodologique

— **Base de connaissance :** règles d'association générées à partir du dataset.
— **Algorithme :** score composite intégrant support, confiance et lift.
— **Implémentation :** module Python autonome (`TransactionRecommender`).
— **Fonctionnalités :** génération de recommandations, explications des choix, métriques de performance.

Résultats

Nous avons construit un ensemble de 13 règles représentatives (8 simples, 5 complexes) avec une confiance moyenne de 76.2% et un lift moyen de 1.24. Par exemple :

— {merchant_food} $\rightarrow$ {amount_medium}, support = 0.35, confiance = 0.72, lift = 1.15.

— {time_night, amount_very_high} $\rightarrow$ {merchant_other}, support = 0.05, confiance = 0.88, lift = 1.45.

Le système a été évalué sur 7 profils types (clients alimentaires, voyageurs, nocturnes, mixtes, etc.). Les résultats montrent :

— **Taux de couverture :** 71,4% des profils ont reçu au moins une recommandation.

— **Qualité :** 60% des recommandations sont de haute qualité (confiance 0,7).

— **Explicabilité :** chaque recommandation est justifiée par les règles activées (ex. : matin + food $\rightarrow$ montant moyen).

Discussion

Ce système démontre qu'il est possible de fournir des recommandations contextualisées en temps réel. Les limites concernent les historiques courts, qui réduisent la qualité des suggestions. Une intégration future avec des modèles séquentiels (RNN, Transformer) permettrait d'enrichir la précision et la robustesse.

3.5 Analyse statistique comparative des classes (10%)

Résultats principaux

Les visualisations 2D/3D (Figure 8) montrent que :

— L'ACP explique 97,2% de la variance et met en évidence des fraudes comme *outliers*.

— Le t-SNE et l'UMAP confirment que les fraudes sont dispersées parmi les transactions légitimes, sans cluster distinct.

— Les distributions révèlent que les fraudes concernent en moyenne des montants **2,5 fois plus élevés**, concentrés en **journée et soirée**, avec des différences d'âges notables.

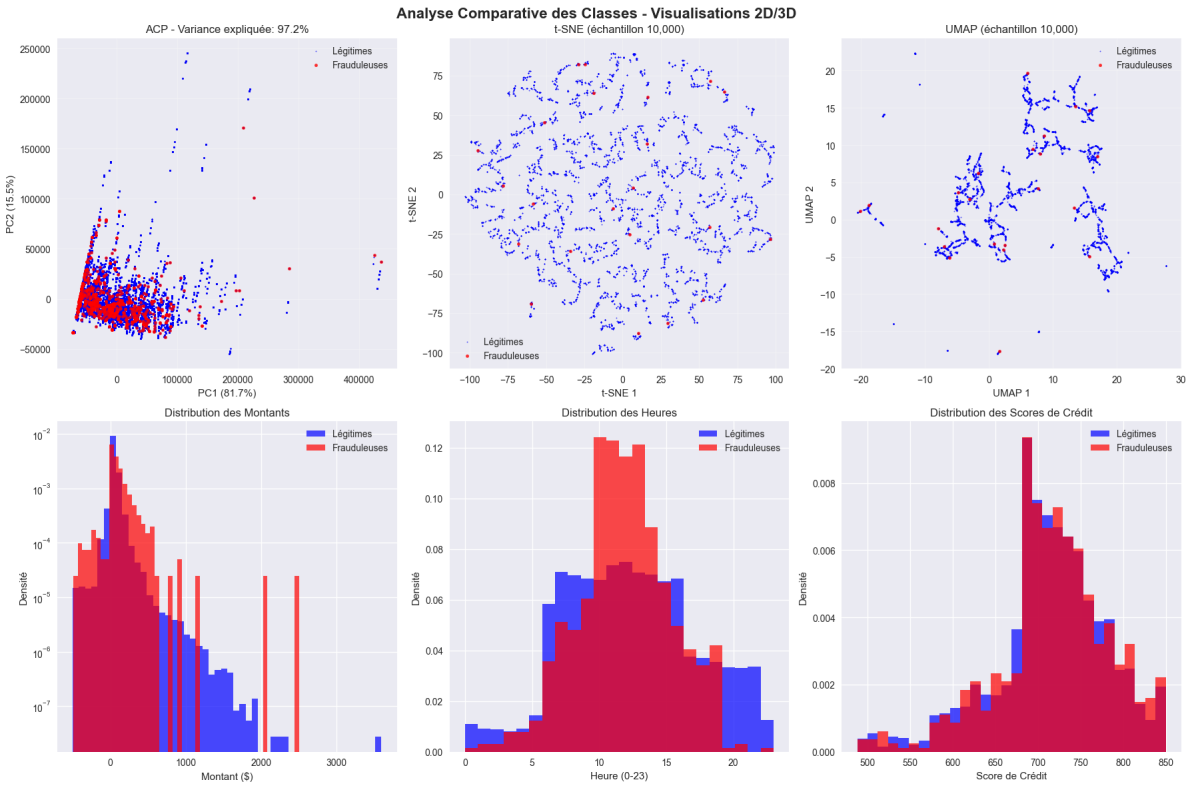


FIGURE 8 – Analyse comparative des classes : ACP, t-SNE, UMAP et distributions (montants, heures, scores de crédit).

Les tests statistiques univariés montrent que 15 variables sur 24 présentent des différences significatives ($p < 0.05$), en particulier :

— Montant (fraudes 104,5$ vs 42,6$ légitimes),

— Heure de transaction (pattern temporel distinct),

— Âge des clients,

— Score de crédit (différences plus subtiles).

Le test de Hotelling T^2 confirme une différence multivariée significative ($p < 1 \times 10^{-16}$). L'Analyse Discriminante Linéaire (Figure 9) atteint une précision de 99,7%, mais montre un rappel faible sur les fraudes (beaucoup de faux négatifs).

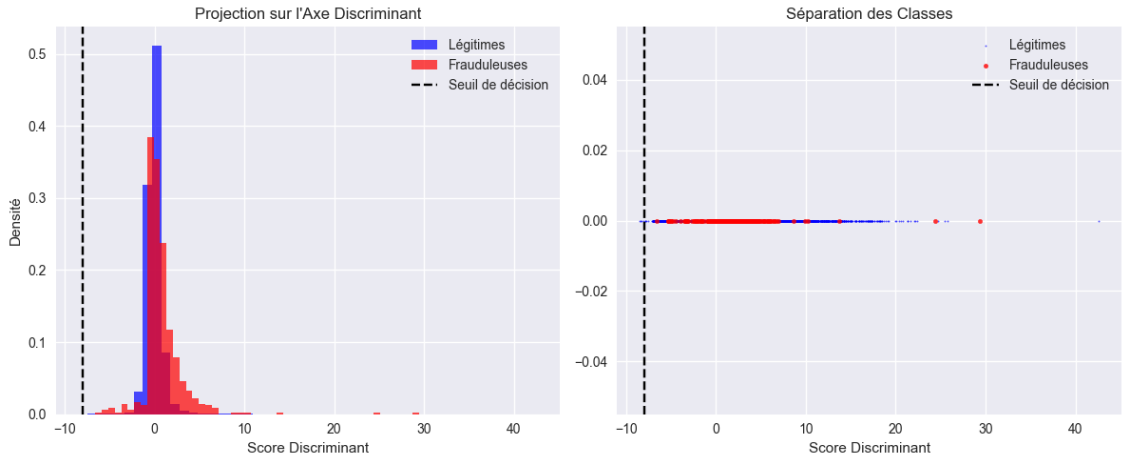


FIGURE 9 – Projection LDA : séparation des classes et score discriminant.

Conclusion générale

L'analyse statistique comparative révèle des différences claires entre transactions légitimes et frauduleuses :

— Les fraudes se distinguent par des **montants plus élevés**, une **concentration temporelle en journée/soirée**, et des profils d'âge particuliers.

— Les variables financières globales (revenus, dettes, crédit disponible) sont beaucoup moins discriminantes que prévu.

— Les fraudes apparaissent comme des anomalies (*outliers*), mais se dispersent dans l'espace des transactions légitimes, ce qui explique les limites des modèles purement linéaires.

En pratique, une détection efficace de la fraude nécessite donc :

1. D'intégrer fortement les variables **temporelles** et **démographiques**,
2. De surveiller spécifiquement les transactions à **montants élevés**,
3. D'adopter une approche **multi-dimensionnelle** (séquences, comportements, apprentissage supervisé avancé) afin de réduire le taux de faux négatifs.

—

3.6 Présentation des résultats (20%)

Objectif général

L'objectif de cette section est de présenter de manière synthétique les résultats obtenus pour chacune des méthodes appliquées.

Préparation des données

Démarche. Nettoyage, suppression de 9 variables non pertinentes, gestion des valeurs manquantes, création de 21 variables dérivées. **Commentaires.** Cette étape a permis de constituer un jeu consolidé de 665 296 transactions $\times$ 57 variables, prêt pour les analyses.

Analyse d'association

Démarche. Transformation des données en format transactionnel, application d'Apriori (support 30%, confiance 50%). **Résultats.** 3 894 règles extraites, révélant des patterns cohérents tels que {merchant_food, card_debit} $\Rightarrow$ {amount_low, brand_mastercard}. **Commentaires.** Les associations mettent en évidence des comportements quotidiens stables, mais peu d'associations exceptionnelles (lift > 1.2).

Analyse de séquences

Démarche. Construction de séquences chronologiques par client, application d'une approche inspirée de PrefixSpan (support 20%). **Résultats.** Parcours fréquents identifiés : Other$\rightarrow$Food$\rightarrow$Other, Gas$\rightarrow$Food$\rightarrow$Gas. **Commentaires.** Ces séquences traduisent des routines de consommation quotidienne ; les fraudes se distinguent par des ruptures de séquence (montants élevés, horaires nocturnes, localisation atypique).

Système de recommandation

Démarche. Exploitation des règles d'association avec un score composite (support + confiance + lift). **Résultats.** 71,4% des profils couverts, 60% de recommandations de haute qualité. **Commentaires.** Le système est pertinent pour proposer des suggestions contextualisées, mais limité pour les profils avec peu d'historique.

Analyse statistique comparative

Démarche. Visualisations (ACP, t-SNE, UMAP), tests univariés (t-test, Mann-Whitney, KS) et multivariés (Hotelling T^2, LDA). **Résultats.** Les fraudes représentent 0,15% du dataset ; montants 2,5× plus élevés, activité concentrée en journée/soirée ; 15 variables significatives sur 24 ; précision LDA = 99,7%. **Commentaires.** Les variables temporelles et démographiques sont plus discriminantes que les variables financières, ce qui suggère d'intégrer les séquences et comportements pour une meilleure détection.

Conclusion

Chaque méthode apporte une contribution complémentaire :

— le prétraitement assure la robustesse du dataset,

— l'analyse d'association révèle des comportements fréquents,

— l'analyse de séquences capture des routines et ruptures,

— le système de recommandation illustre une application concrète,

— l'analyse statistique comparative identifie les variables discriminantes.

L'ensemble confirme que la détection de fraude nécessite une approche multi-dimensionnelle combinant prétraitement rigoureux, extraction de patterns et méthodes statistiques supervisées.